

A1.6 Regresión no lineal

En esta actividad trabajaremos con una base de datos que generé en el semestre de Otoño 2022 en mi clase de Sistemas Digitales en la Universidad de Monterrey. En dicha materia, cada semana se entregan actividades y la bandeja de entrega se cierra cada domingo a medianoche. Con mi experiencia impartiendo esta clase, tengo la sospecha de que entre más cerca de la hora de cierre de la bandeja se entrega la tarea, peor la calificación en la misma. Ayúdame a confirmar o rechazar mi hipótesis.

Utilizaremos el archivo de nombre “A1.6 Tiempo de Entrega.csv”, donde podrás encontrar información para 432 actividades entregadas, organizadas de la siguiente manera:

- **“Tiempo”**. Tiempo restante para que se cerrara la bandeja, en horas. Es decir, un 1 indica que entregaron la actividad el domingo a las 11:00 p.m., y un 48 indica que entregaron la actividad 48 horas antes del domingo a medianoche.
- **“Calificacion”**. Calificación obtenida, en una escala entre el 0 y el 110.

Desarrolla los siguientes puntos en una *Jupyter Notebook*, tratando, dentro de lo posible, que cada punto se trabaje en una celda distinta. Los comentarios en el código siempre son bienvenidos, de preferencia, aprovecha el *markdown* para generar cuadros de descripción que ayuden al lector a comprender el trabajo realizado.

1. Importa los datos del archivo “Tiempo de entrega.csv” a tu ambiente de trabajo. Este archivo lo encontrarás en la misma página donde descargaste esta plantilla. Genera una gráfica de dispersión que muestre el comportamiento de los datos. Agrega una línea de texto en la que generes una predicción sobre qué tipo de algoritmo será el más adecuado para resolver la tarea (no hay respuestas correctas).
 - i. **NOTA:** Si te encuentras con algo “raro”, te recomiendo que abras el archivo csv en Excel o alguna herramienta similar y revises qué podría estar causando el error. Cuando lo encuentres, toma alguna acción al respecto para solucionar el problema, e indica en la celda de la libreta la acción que tomaste y el por qué. No se evaluará la acción realizada, pero servirá para discusión en clase.
2. Separa los datos en entrenamiento y prueba, con una relación de 70/30. Imprime en consola el promedio de los tiempos en el conjunto de entrenamiento y en el conjunto de prueba. Haz lo mismo para las calificaciones. Incluye una línea de texto donde comentes sobre la similitud o diferencia de los valores promedio entre el conjunto de entrenamiento y el de validación, y cómo es que esto podría afectar al análisis.
3. Entrena un modelo de regresión polinomial usando los datos de entrenamiento; puedes usar el orden de polinomial que consideres más adecuado. Imprime un resumen de los resultados obtenidos y agrega una línea de texto en la que comentes sobre el tipo de relación (positiva o negativa; ¿a menor tiempo menor calificación?) entre el término lineal y la respuesta, lo que esto significa y si dicha variable está significativamente asociada con las calificaciones.
4. Entrena un modelo de regresión segmentada, siguiendo la misma estrategia utilizada en la lectura interactiva, utilizando regresiones cuadráticas para cada segmento. Genera estimaciones (predicciones) en los datos de validación. Asegúrate de usar la función descrita en la lectura interactiva, instalándola en tu ambiente de trabajo en caso de no haberlo hecho previamente.

5. Entrena un modelo KNN para regresión utilizando el valor de k que consideres adecuado (o prueba con varios). Genera estimaciones en los datos de validación.
6. Calcula el RSE en los datos de prueba para los 3 modelos y agrega una línea de texto donde comentes sobre sus diferencias y si hay un claro “ganador”. No te bases exclusivamente en el error, puedes considerar también aspectos como la interpretabilidad del modelo.
7. Para los datos de prueba, grafica tanto las calificaciones reales como las predichas por los 3 modelos en un mismo *plot*, asegurándote de utilizar etiquetas, colores y/o distintos marcadores para diferenciar y describir a cada modelo.