

P P1. Regresión

En este proyecto estarás trabajando con datos de tu interés, ya sea que los descargues de alguna base de datos pública o que los hayas generado por tu cuenta.

Desarrolla los siguientes puntos en una *Jupyter Notebook*, de forma que se genere un reporte fácilmente comprensible, interpretable y replicable, con información para el lector descrita en formato de markdown. Indica claramente de dónde descargaste los datos, y los objetivos específicos que se desean alcanzar con el proyecto (e.g. identificar si a partir de información relacionada a la calidad del aire puedo predecir la temperatura, y caracterizar la relación que existe entre la cantidad de partículas pm25 y la temperatura).

1. Importa los datos a tu ambiente de trabajo. Describe características de tu base de datos, imprimiendo en consola y graficando información relevante. Por ejemplo: cantidad de observaciones, cantidad de variables, tipo de variables, nombre de variables, identificación de la respuesta de interés, etc. Asegúrate de que tus variables tengan un nombre fácilmente interpretable. En caso contrario, adjunta también un diccionario, un archivo .docx, .xlsx, .pdf, .csv, etc. donde se describa cada variable (por ejemplo: var1. Peso medido en gramos, var2. Diámetro medido en centímetros). Explica claramente qué de esta información te permitió suponer que realizar una regresión lineal pudiera ser una buena solución y/o por qué supones que otro método sería una mejor opción.
2. Aplica soluciones para al menos tres de los cinco problemas típicos que se describieron en la presentación C1.5. Demuestra las modificaciones que se le realizaron a la base de datos, imprimiendo en consola información relevante, y explica por qué se realizaron. Por ejemplo: para el caso de variables cualitativas, podrías imprimir la cantidad y los nombres de las variables antes de aplicar la solución, y la cantidad y los nombres de las variables después de aplicar la solución.
3. Realiza un proceso de selección de características. Puedes llevar a cabo una metodología de selección hacia adelante o eliminación hacia atrás, o incluso mezclarlas. También puedes utilizar un método de regularización. Evidencia tus resultados imprimiendo en consola la cantidad y los nombres de las variables antes y después del proceso de selección de características. Explica claramente por qué utilizaste la metodología empleada, así como alguna conclusión sobre los resultados de este proceso.
4. Genera un modelo de regresión lineal y al menos uno no lineal, para predecir una variable de interés; explica con detalle por qué seguiste los pasos mostrados en tu código para generar el modelo, en aras de obtener la mejor predicción y resultados generalizables. Imprime en consola los coeficientes estimados al entrenar el modelo, e indica para cuáles de ellos puedes afirmar que existe una asociación significativa con la respuesta, y el por qué de tu aseveración.
5. Calcula al menos una métrica de error y una del nivel de linealidad del modelo, con la intención de que ambas métricas representen el funcionamiento esperado del modelo para cualquier dato que se le presente. Agrega un comentario que describa en palabras sencillas el significado de los mismos.
6. Genera un modelo de regresión lineal o no lineal (del mismo tipo que el que haya obtenido el mejor desempeño en los puntos anteriores), pero para realizar un análisis de inferencia. A partir del mismo, realiza una o varias inferencias sobre los datos, asegurándote de incluir márgenes de error para tus conclusiones.

7. (Opcional, valor de 10 puntos extra, solamente válido si utilizaste datos de <https://www.inegi.org.mx/datosabiertos/>) Crea una presentación corta (aproximadamente 5 slides), y expón al grupo la metodología y resultados obtenidos, como si estuvieras presentando resultados a una entidad responsable de resolver problemáticas sociales. Sube la presentación en la bandeja de Blackboard junto con el resto de los documentos.